

Introducción teórico-práctica al Aprendizaje por Refuerzo

Clase 1 — Introducción

Profesor: Matias Bilkis



UBA
Universidad de Buenos Aires



Inteligencia artificial...

Mito del Golem


El poema El GOLEM, por Jorge Luis Borges

Si (como el griego afirma en el Cratilo)
El nombre es arquetipo de la cosa,
En las letras de rosa está la rosa
Y todo el Nilo en la palabra Nilo.
Y, hecho de consonantes y vocales,
Habrá un terrible Nombre, que la esencia
Cifre de Dios y que la Omnipotencia
Guarde en letras y sílabas cabales.
Adán y las estrellas lo supieron
En el Jardín. La herrumbre del pecado
(Dicen los cabalistas) lo ha borrado
Y las generaciones lo perdieron.
Los artificios y el candor del hombre
No tienen fin. Sabemos que hubo un día
En que el pueblo de Dios buscaba el Nombre
En las vigiliass de la judería.
No a la manera de otras que una vaga
Sombra insinúan en la vaga historia,
Aún está verde y viva la memoria
De Judá León, que era rabino en Praga.
Sediento de saber lo que Dios sabe,
Judá León se dio a permutaciones
de letras y a complejas variaciones
Y al fin pronunció el Nombre que es la Clave.
La Puerta, el Eco, el Huésped y el Palacio,
Sobre un muñeco que con torpes manos
labró, para enseñarle los arcanos
De las Letras, del Tiempo y del Espacio.
El simulacro alzó los soñolientos
Párpados y vio formas y colores
Que no entendió, perdidos en rumores
Y ensayó temerosos movimientos.
Gradualmente se vio (como nosotros)
Aprisionado en esta red sonora
de Antes, Después, Ayer, Mientras, Ahora,
Derecha, Izquierda, Yo, Tú, Aquellos, Otros.
(El cabalista que ofició de numen
A la vasta criatura apodó Golem;
Estas verdades las refiere Scholem
En un docto lugar de su volumen.)
El rabí le explicaba el universo
"Esto es mi pie; esto el tuyo; esto la sogá."

[El Gólem, JBL]



*Juda León
(rabino)*



El Golem



[The Golem, Wegener]

Golem

[Haciendo un “uso conveniente” del relato]...

El rabí le explicaba el universo //
esto es mi pie; esto el tuyo, esto la soga //

y logró, al cabo de años, que el perverso //
barriera bien o mal la sinagoga

[\[El Gólem, JBL\]](#)



Golem

Lo primero que hace el Rabí: “enseñar”

El rabí le explicaba el universo //

esto es mi pie; esto el tuyo, esto la soga //

y logró, al cabo de años, que el perverso //
barriera bien o mal la sinagoga

[\[El Gólem, JBL\]](#)



Golem

... pero no le sale tan bien:

*... // "no aprendió a hablar,
el aprendiz de hombre" //*

*El rabí le explicaba el universo //
esto es mi pie; esto el tuyo, esto la soga //*

*y logró, al cabo de años, que el perverso // barrierá
bien o mal la sinagoga*

¿Falló el Golem?

Incluso si pudiese “hablar” (ejemplo, los LLMs)...
...podemos definir “aprender” el Universo?

[\[El Gólem, JBL\]](#)

Golem: más preguntas que respuestas

- *¿Cuándo* diríamos “el Golem ya aprendió”?
- ¿Es suficiente con balbucear?
¿Los LLMs hablan, o solo “responden”?
- ... la frontera de estas definiciones es difícil, lógico...
“¿Def. inteligencia? ¿Frontera artificial vs. vivo?, etc.”
Lo más lindo de la IA [IMO] es lo interdisciplinario.

[\[El Gólem, JBL\]](#)

Una aproximación a definir IA

Def. Inteligencia artificial como la capacidad de un sistema para tomar decisiones, a través de la experiencia y de manera autónoma, para fijar y lograr un objetivo.

¿Están de acuerdo? ¿Nos quedamos cortos?

El rabí le explicaba el universo //

esto es mi pie; esto el tuyo, esto la sogá //


y logró, al cabo de años, que el perverso // barriera bien o mal la sinagoga



Una aproximación a definir IA

Def. Inteligencia artificial como la capacidad de un sistema para tomar decisiones, a través de la experiencia y de manera autónoma, para fijar y lograr un objetivo.

Para mi se queda corto porque...




[The era of experience]

Reinforcement Learning

Señal de guía: el reward

Def. Inteligencia artificial como la capacidad de un sistema para tomar decisiones, a través de la experiencia y de manera autónoma, para fijar y lograr un objetivo.


El RL se trata de optimizar esta toma de decisiones en escenarios secuenciales, para encontrar una conducta “objetivo”, (e.g. barrer la sinagoga) a través de una señal que se llama premio/reward



Enternamos a un perrito para...

Decimos “sit”:

- si se sienta: premio
- si NO se sienta: nada de premio



[Perros de Pavlov]

El rabino “entrena” al Golem para..

Si barre OK → premio


Si NO barre premio = 0

Noción de prueba & error

El rabí le explicaba el universo //

esto es mi pie; esto el tuyo, esto la soga //

y logró, al cabo de años, que el perverso //
barriera bien o mal la sinagoga



El premio puede ser negativo

Alguna vez aprendimos [por las malas] que si sale mucho vapor... seguramente nos quemamos. *Experiencia.*



[\[Instituto Nacional de la Yerba Mate\]](#)

Un framework bastante general

¿Cómo me conviene ir a la UBA?

Por “experiencia” si es hora pico, la Illia estará colapitada.



¿Qué es el Reinforcement Learning?

Def. Es [un] marco que estudia el aprendizaje [artificial] a través de la experiencia.


¿Por qué atajarse tanto? en DeepMind lo definen como “el marco teórico/conceptual” [\[UCL x Deepmind '21 | Clase 1\]](#)

Como todo, es discutible... [\[why AI systems don't learn\]](#)
pero RL no deja de ser un marco *importantísimo*

RL como un marco importantísimo


machine learning

unsupervised
learning




*El Gólem mira el piso y
descubre
“patrones”/”etiquetas”
(si está roñoso, o si está limpio)*

supervised
learning



*El rabino le
muestra fotos
“limpio”/”sucio”*

reinforcement
learning




*El rabino lo guía
con premios*



RL = interdisciplinarietà



*Machine
learning*



Neuroscience



*Teoría de
control*

(y más...)



Más ejemplos



Ajedrez.

¿Qué pieza mover ahora? ¿Cómo predecir probabilidad de éxito?



Refrigeración.

¿Mantener frío a gasto mínimo?



“Rumba” (robot-barrer).

Planificar recorrido, seguir limpiando o volver a cargar batería, ¿y si quedó sucio?

Stock.

¿Cuánto pongo de cada cosa dado el contexto?

Algunos desafíos con RL



Señales muy tenues

Solo sabemos si el movimiento fue bueno cuando ganamos / perdimos la partida.

Modelo: ¿Sí o no?

¿Y si desconocemos las reglas del juego de antemano?

Adaptación.

Si viene una ola de compradores de Danonino... el método tiene que poder adaptarse a esta situación (reponer mucho Danonino)

Explorar vs. Explotar

Si el living está demasiado sucio: ¿me quedo limpiando o voy a limpiar la cocina, antes que se me acabe la batería? ¿y si la cocina ya estaba limpia? ¿o más sucia?

Momento 🤖 (Deep reinforcement Learning)

Deep reinforcement learning


Golem = red neuronal




Breakout, Atari 2600, siendo jugado x RL
score 400 (RL) vs. 30 (“professional” human)

[\[Human-level control through deep reinforcement learning\]](#)

Deep reinforcement learning




Breakout, Atari 2600, siendo jugado x RL
score 400 (RL) vs. 30 (“professional” human)



Una aproximación a definir IA

Def. Inteligencia artificial como la capacidad de un sistema para tomar decisiones, a través de la experiencia y de manera autónoma, para fijar y lograr un objetivo.

¿Están de acuerdo? ¿Nos quedamos cortos?



[The era of experience]

[Human-level control through deep reinforcement learning]

Deep reinforcement learning


Chess



Shogi



Go



[\[The thinking game\]](#)

June 25, 2018 Milestone



OpenAI Five

Our team of five neural networks, OpenAI Five, has started to defeat amateur human teams at Dota 2.



[\[Dota 2 || OpenAI Five || 2018\]](#)

Deep reinforcement learning




El marco del RL

El loop genérico de RL




- *Un agente interactúa con su entorno de manera secuencial.*
- *El agente recoje información y actúa*

El loop genérico de RL



- Información: “premio” R_t y “estado” S_t
- Acción A_t elegida por el agente bajo cierta política.

(Very much) toy model




$$\mathcal{A} = \{x, o\}$$
$$\mathcal{S} = \{x, o\}$$
$$\mathcal{P}(r | s a) = \begin{cases} 1 & \text{si } S=a \\ 0 & \text{Sino} \end{cases}$$

¿Cuál es la política π óptima?

- Información: “premio” R_t y “estado” S_t
- Acción A_t elegida por el agente bajo cierta política.

El loop genérico de RL




- Dinámica “Entorno”

$$p_E(s', r | h = H_t) = p_E(s' = S_t, r = R_t | h = H_t)$$


- Historia $H_t = (S_0, A_1, R_1, S_1, A_2, \dots, A_{t-1}, R_{t-1}, S_t)$

Premios & temporalidad $R_t \in \mathbb{R}$

- R_t es el premio que el agente obtiene a cada “*paso*”
- La idea es que R_t guíe al agente: tiene que obtener tantos premios como le sea posible, durante un “*episodio*”



El escenario genérico de RL



- S_t R_t son **variables aleatorias**. También A_t
- Para cada episodio, vamos a obtener diferentes valores, que dependen del entorno.
- Política del agente $\pi(A_t|S_t)$

El objetivo de RL

Obtener el **máximo retorno** dentro de un episodio

$$G_t = R_t + R_{t+1} + \dots R_L$$

¿Cómo venimos?

¿Les parece que está bien formulado esto?

El objetivo de RL

Obtener el **máximo retorno** dentro de un episodio

$$G_t = R_t + R_{t+1} + \dots R_L$$

¿Cómo venimos?

¿Les parece que está bien formulado esto?

$v(s) = \mathbb{E}[G_t | s = S_t]$ *¿De qué “objetos” debería depender este valor esperado? (pista = p^2)*

¿Sobre qué tiene control el agente?

La **política** del agente = regla decisión tomar acciones

$$\pi(a|s)$$

¿Qué acción $a = A_t$ elijo si $s = S_t$?

$$v(s) = \mathbb{E}[G_t | s = S_t] \longrightarrow v_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s]$$

Una intuición sobre “el valor”

La **función valor** cuantifica cuán valioso es un estado

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s]$$

Si modificamos la política para que los estados sean más valiosos... ¿estamos! ¿estamos?



Modelo: ¿Sí o no?

Señales (R_t) escasas...



Adaptación ($p_E \rightarrow p_E'$)




Explorar vs. Explotar

Un ejemplito


Laberinto

Start

Gridworld 4x4 - reward -1 por paso hasta llegar a la meta (G)
Politica uniforme aleatoria
 $v_{\pi}, \gamma = 1$




Politica optima (determinista)
 $v_*, \gamma = 1$



Reward = -1 en cada casillero, hasta llegar a G
Si choca con pared, queda ahí (y reward -1)

En clase 3 veremos cómo calcular $v(s)$
que cuantifica cuán valioso es cada estado


Laberinto con “pozos”



Gridworld

22.0	24.4	22.0	19.4	17.5
19.8	22.0	19.8	17.8	16.0
17.8	19.8	17.8	16.0	14.4
16.0	17.8	16.0	14.4	13.0
14.4	16.0	14.4	13.0	11.7

v_*



π_*

$R_t = \{0, -1, 10, 5\}$
-1 si chocás pared
10 si caés en A
5 si caés en B
0 sino

Dinámica:
normal salvo pozos {A,B}

Mensaje

Si sabemos $v(s)$ y además conocemos p_E
→ ¡estamos! → pero en general...

... *todo RL gira en torno a esto.*



Modelo: ¿Sí o no?
Señales (R_t) escasas...



Adaptación ($p_E \rightarrow p'_E$)



Explorar vs. Explotar

La hipótesis del reward

Vale la pena rescatar que todo el RL se basa en la idea de que una conducta “objetivo” puede formularse como la maximización de un reward.

- ¿Es suficientemente general?
- ¿Reward + prueba & error = AGI?


[Reward is enough]



Una aproximación a definir IA

Def. Inteligencia artificial como la capacidad de un sistema para tomar decisiones, a través de la experiencia y de manera autónoma, para fijar y lograr un objetivo.

¿Están de acuerdo? ¿Nos quedamos cortos?



[The era of experience]

Los elementos del RL

(sintetizando lo anterior)

Elementos de RL



Entorno

- Se encuentra en un “estado” S_t
- Dada una acción del agente A_t revela R_t
- Y además cambia su estado
- Las reglas (aleatorias!) están dadas por
$$p_E(s', r|h = H_t) = p_E(s' = S_t, r = R_t|h = H_t)$$



Agente

- Observa el estado del entorno S_{t+1}
- Elige acciones de acuerdo a una política π
- Busca maximizar el **retorno** (suma rewards)

¿Cómo son las reglas del entorno?



En general, asumimos un entorno es “Markoviano”

$$p_E(s', r|h = H_t) = p_E(s' = S_t, r = R_t|h = H_t)$$

Entorno



$$p_E(s', r|h = H_t) = p_E(s' = S_t, r = R_t|s = S_{t-1}, a = A_{t-1})$$


Esto resulta en un **proceso de decisión de Markov**
a menos que ...

Partially-Observable MDPs

... A menos que el agente no pueda observar todo su entorno (y en la práctica sucedería... pues el mundo es muy grande!)

En tal caso, distinguimos entre:


- *Estado del entorno*
- *Estado del agente (reconstruye / aproxima) estado entorno*
- *Una reconstrucción puede ser utilizar historia interacciones*



Partially-Observable MDPs


- Dejaremos de lado los POMDPs
“asumiremos que la reconstrucción del agente es fidedigna”
- La dinámica de los estados (y del premio!) la denotaremos

$$p(s', r | s, a) \equiv p_E(s' = S_t, r = R_t | s = S_{t-1}, a = A_{t-1})$$



$$S_{t+1} \sim p(s' | s = S_t, a = A_t)$$

$$R_{t+1} \sim p(r | s = S_t, a = A_t)$$



Las muchas dimensiones del *aprendizaje* en RL

¿Qué recursos podría usar el agente?

- Estimar los value-functions $v(s)$ || *value-based*
- Enfocarse directamente en la política || *policy-based*
- Estudiar “cómo sería una política” pero siguiendo otra
on-policy vs. off-policy
- Intentar aproximar un modelo del entorno
model-free vs. model-based learning



Y todas las combinaciones que uno se pueda imaginar

La política del agente $\pi(a|s)$

- Distinguimos entre métodos que derivan la política de estimaciones de la **función valor** (value-based)
- Y de métodos que parametrizan la política directamente, y eligen las acciones a partir de esa parametrización.
- La política puede ser determinística o también estocástica (depende el problema, la óptima es determinista o no)



¿Qué recursos podría usar el agente?

on-policy vs. off-policy

**model-free vs.
model-based**

value vs. policy

**MC vs.
TD**



Ejemplo: Q-learning (en 1 mes)

off-policy

model-free

value-based

TD





Los diversos problemas que surgen con RL

Espacios enormes


¿Podemos aproximar el $v(s)$ para estados que no vimos?




No llegamos a explorar todo el espacio de (estados-acciones), porque hay demasiados!



Intestabilidad de entrenamiento



Explotación vs. exploración



Introducción teórico-práctica al RL

¿A dónde vamos?

Warmup
bandit

Resolver MDP
(full modelo)

**Estimar valores
via interacción**
(online, off-line)

**Optimizar la
política**
directamente

Aproximar via
deep learning

DQNs

PPO

Otras cosas
[no menos]
importantes

¿A dónde vamos?

Intro

Bandits
MDPs
DynPro

MC
TD
PB

NNs

DQNs

PPO

Papers
(estudiar)


MB

Frontier

Posters

¿Quienes
cursaron
ML2?



Puntos “de llegada” del curso



Deep Q-networks || carrito-palito

Hay que balancear el palito, empujando la carretilla a derecha o izquierda con fuerza +1N ó -1N

Estados: (x, v, θ, ω) . Acciones: $\{-1, 1\}$, Reward: +1 hasta que se cae el palito. *Política basada en estimar values!*



Proximal Policy Optimization

Aterrizando una nave

Estados $(x, y, v_x, v_y, \theta, \omega, \text{aterrizó}_1, \text{aterrizó}_2)$




Acciones $[\text{motor}_1, \text{motor}_2]$ (**continuas** en $[-1, 1]$)

Política: gaussiana parametrizada sobre la potencia de cada motor


Reward: a cada t si se desvía, penalizamos combustible, y premiamos si aterriza las dos patas (dentro).

PPO — Recién empezando

Episodio de entrenamiento ~85 / 2907 | paso del episodio: 0



¿Qué me importa del curso?

- Es “fácil” hacer plug-and-play de DQN // PPO
- Incluso es fácil vibe-codearlo...The logo for Claude Code, featuring the words "CLAUDE" and "CODE" in a stylized, orange, blocky font with a slight 3D effect.
- No es tan sencillo entender los elementos e ideas.
Esto es lo que importa, y la razón por la que estamos acá.

Fijando expectativas

En este curso (y siempre, i guess) ideas >> código.

Grupos de 5p: discutir & entregables & “comité avisos”


Heterogeneos en carrera y en año, please!

Comunicaciones a través del Campus. Foro.


No responderé dudas. Sí las leeré. mbilkis@liaa.dc.uba.ar

Cada semana habrá algo que leer/programar en grupo.


Bibliográfia



Sutton & Barto
(referencia ppal)



Bertsekas




Szepesvári

La relevancia del RL hoy


Reinforcement Learning from Human Feedback (RLHF)



*... // uno aprendió a hablar,
el aprendiz de hombre" //*




LLMs



*Fine-tune LLM towards
(an inferred) user- reward model
usando un algoritmo de RL (PPO & variants)*

Tarea



Sutton & Barto

(1) Leer Capítulo 1 Sutton & Barto

(2) Leer [\[The era of experience\]](#)

Discutir entre el grupo y escribir un resumen de una página (uno por grupo) subirlo al campus.

Lo que no entiendan digan NO entendí...