

Introducción teórico-práctica al Aprendizaje por Refuerzo

Clase 3— MDPs

Profesor: Matias Bilkis



UBA
Universidad de Buenos Aires




¿Cómo les fue con la tarea?



¿De dónde venimos y hacia dónde vamos? 🧐🧐


Bandits →
“evaluar”



$$R_t \sim p(r|a = A_t)$$

$$q_*(a)$$

MDPs →
“evaluar”
“asociar”



$$S_{t+1} \sim p(s'|s = S_t, a = A_t)$$

$$R_{t+1} \sim p(r|s = S_t, a = A_t)$$

$$Q_*(s, a)$$

Sobre lo teórico y las aplicaciones

La cota de Lai-Robbins

Teorema Lai-Robbins (1985) [\[Lai Robbins Bound\]](#)

$$L_T \geq \log T \sum_{a \neq *} \frac{\Delta_a}{\text{KL}(p_a(R) || p_*(R))}$$
$$\text{KL}(p|q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \quad \text{o} \quad \int p(x) \log \frac{p(x)}{q(x)}, dx$$

¿Qué comportamiento esperamos para epsilon-greedy?

Resultados:
para la familia indicada, TS satura el bound
UCB tiene, en general, el scaling óptimo

Del Rigor en la Ciencia

[Minicuento - Texto completo.]


Jorge Luis Borges

En aquel Imperio, el Arte de la Cartografía logró tal Perfección que el mapa de una sola Provincia ocupaba toda una Ciudad, y el mapa del Imperio, toda una Provincia. Con el tiempo, estos Mapas Desmesurados no satisficieron y los Colegios de Cartógrafos levantaron un Mapa del Imperio, que tenía el tamaño del Imperio y coincidía puntualmente con él.

Menos Adictas al Estudio de la Cartografía, las Generaciones Siguientes entendieron que ese dilatado Mapa era Inútil y no sin Impiedad lo entregaron a las Inclemencias del Sol y los Inviernos. En los desiertos del Oeste perduran despedazadas Ruinas del Mapa, habitadas por Animales y por Mendigos; en todo el País no hay otra reliquia de las Disciplinas Geográficas.

Suárez Miranda, *Viajes de Varones Prudentes*, Libro Cuarto, Cap. XLV, Lérida, 1658.

FIN




(tampoco seamos idiotas...)



Bandits

Problema de los bandidos

Tenemos k distribuciones de probabilidad diferentes.





- Cada $p.d.f.$ nos da un reward si la sampleamos.

$$R_t \sim p(r|a = A_t)$$

- El agente desconoce $p(r|a = A_t)$

Markov Decision Process



El loop genérico de RL



- Usamos R_{t+1} para denotar el reward luego de A_t (porque se obtiene del mismo par $(R_{t+1}, S_{t+1}) \sim P(\cdot | A_t S_t)$)

Llamamos **dinámica del entorno** a $p(s' r | s, a)$

El loop genérico de RL



Los estados, acciones y rewards tienen sus conjuntos

$$S_t \in \mathcal{S}$$

$$A_t \in \mathcal{A}(S_t)$$

$$R_{t+1} \in \mathcal{R}$$

¿Jugamos a ser “dios”?

MDP = F² (Framework Flesible)

El rabino “entrena” al Golem para..


Si barre OK → premio

Si NO barre premio = 0


Noción de prueba & error

El rabí le explicaba el universo //
esto es mi pie; esto el tuyo, esto la sogá //

y logró, al cabo de años, que el perverso //
barriera bien o mal la sinagoga




En la hora de angustia y de luz vaga, //
en su Golem los ojos detenía. //
¿Quién nos dirá las cosas que sentía //
Dios, al mirar a su rabino en Praga?



- Flexible (separación entre agente / entorno)
- La reward signal es externa... (indicar qué queremos)

¿Jugamos a ser “dios”?



*En la hora de angustia y de luz vaga, //
en su Golem los ojos detenía. //
¿Quién nos dirá las cosas que sentía //
Dios, al mirar a su rabino en Praga?*




- Los MDPs son un framework MUY flexible
- Agente // Entorno ¿dónde está la separación?
- ¿Cómo elijo el reward signal?

El loop genérico de RL

En Clase 1 dijimos $\rightarrow$ Entornos Markovianos.

Estudiaremos situaciones donde el estado S_t it's “*all i need*”




$$p(s'r|h) \rightarrow p(s'r|s)$$



Russian mathematician
Andrey Markov


***All i need..
¿Para qué?***

El loop genérico de RL



La interacción define una **trayectoria** sobre estos conjuntos, e.g. una realización del “proceso”

TRAYECTORIA



EPISODIO 1




EPISODIO 2



(...)

EPISODIO N



$(S_0, A_0 R_1 S_1 A_1, \dots, S_{T-1}, A_{T-1} \mathbf{R}_T, \mathbf{S}_T)$

¿Se entiende diferencia
entre T y N?

S_T *terminal state*

Sobre la env dynamics

Distribuciones marginales... $p(s'|s, a) = \sum_r p(s'r|s, a)$

Valores medios $\mathbb{E}[R_{t+1}|S_t = s, A_t = a] = ?$


Conditional Probability Formula

$$P(A|B) = \frac{\text{Probability of } A \text{ and } B}{\text{Probability of } A \text{ given } B} = \frac{P(A \cap B)}{P(B)}$$

Probability of A and B
Probability of A given B
Probability of B

$\mathbb{E}[R_{t+1}|S_t = s, A_t = a, S_{t+1} = s'] = ?$

Ojo, que si bien parece muy inocente, son los objetos que generan todo el espacio... (junto a π)





Ejemplito

Ejemplito 3.3 (S&B)

$$\mathcal{S} = \{ \textit{high}, \textit{low} \}$$


$$\mathcal{A}(\textit{low}) = \{ \textit{buscar}, \textit{esperar}, \textit{recargar} \} \quad \mathcal{A}(\textit{high}) = \{ \textit{buscar}, \textit{esperar} \}$$

$$R_t = \begin{cases} +1 & \text{si agarra lata} \\ -3 & \text{se queda s/ pilas} \end{cases} \quad || r_{\textit{wait}}, r_{\textit{search}} \text{ son valores medios}$$



s	a	s'	$p(s' s, a)$	$r(s, a, s')$
high	search	high	α	r_{search}
high	search	low	$1 - \alpha$	r_{search}
low	search	high	$1 - \beta$	-3
low	search	low	β	r_{search}
high	wait	high	1	r_{wait}
high	wait	low	0	-
low	wait	high	0	-
low	wait	low	1	r_{wait}
low	recharge	high	1	0
low	recharge	low	0	-

¿Jugamos a ser “dios”?




*En la hora de angustia y de luz vaga, //
en su Golem los ojos detenía. //
¿Quién nos dirá las cosas que sentía //
Dios, al mirar a su rabino en Praga?*

- Fijate que podríamos haber definido diferente los rewards
- En lugar de 0, darle un súper premio si no se apaga batería
- Recordemos **reward hypothesis...**


El retorno & objetivo RL

El objetivo de RL

En Cl.1 definimos el retorno según $G_t = R_{t+1} + R_{t+2} + \dots + R_T$



$(S_0, A_0, R_1, S_1, A_1, \dots, S_{T-1}, A_{T-1}, R_T, S_T)$ $(\dots)$



El episodio puede no-terminar (wander in the galaxy 4 ever)

Tipos de episodio





Horizonte fijo

T fijo



Horizonte fijo
(indefinido)

T variable aleatoria



Horizonte
infinito
(tareas continuas)

$T = \infty$

La buena definición del G_t

Definimos el retorno descontado $\gamma \in [0, 1]$

$$G_t = \sum_{k=0}^T \gamma^k R_{t+k+1}$$


$$G_t = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{t+k-1} R_{t+1+k} + \dots + \gamma^{T-t} R_T$$

$$\gamma = 0$$

“cortoplazista”

$$\gamma \sim 1$$

“largoplazista”



S_T *terminal state*
(*finite-horizon*)

Memento “práctica”

¿Quién se anima a resolverlo?

Exercise 3.8 Suppose $\gamma = 0.5$ and the following sequence of rewards is received $R_1 = -1$, $R_2 = 2$, $R_3 = 6$, $R_4 = 3$, and $R_5 = 2$, with $T = 5$. What are $G_0, G_1, \dots, G_5$? Hint: Work backwards. $\square$

Exercise 3.9 Suppose $\gamma = 0.9$ and the reward sequence is $R_1 = 2$ followed by an infinite sequence of 7s. What are G_1 and G_0 ? $\square$

$$G_t = \sum_{k=0}^T \gamma^k R_{t+k+1}$$

“**Hint**” usar serie geométrica

$$\sum_{k=0}^{\infty} x^k = \frac{1}{1-x}$$

Policies & value-functions

Cuán buena es una policy?

La **política** del agente = $\pi(a|s)$ $v_\pi(s) = \mathbb{E}_\pi[G_t | S_t = s]$

¿Qué acción $a = A_t$ elijo si $s = S_t$

En primer lugar, qué pinta tiene

$$\mathbb{E}_\pi[R_{t+1} | s] = ??$$

Cuán buena es una policy?

La **política** del agente = $\pi(a|s)$ $v_\pi(s) = \mathbb{E}_\pi[G_t | S_t = s]$

¿Qué acción $a = A_t$ elijo si $s = S_t$

En primer lugar, qué pinta tiene

$$\mathbb{E}_\pi[R_{t+1}|s] = \sum_{a,r'} r' p(r'|sa) \pi(a|s)$$

Cuán buena es una policy?

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s] = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right]$$

Obviamente depende de la policy

Para el “terminal state” S_T (si existe) es zero.

Memento Bellman



Ecuaciones de Bellman

Por la definición misma del return

$$\begin{aligned} G_t &= R_{t+1} + \gamma G_{t+1} \\ v_\pi(s) &= \mathbb{E}_\pi[G_t | S_t = s] \\ &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) \left(r + \gamma \mathbb{E}_\pi[G_{t+1} | S_{t+1} = s'] \right) \\ &= \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) \left(r + \gamma v_\pi(s') \right) \\ &= \sum_{r, a} r p(r | s, a) \pi(a | s) + \gamma \sum_{a, s'} \pi(a | s) p(s' | s, a) v_\pi(s') \end{aligned}$$

El value-function tiene que ser igual al promedio del próximo reward, más los value functions por venir!

Ejemplo GridWorld

Example 3.5: Gridworld Figure 3.2 (left) shows a rectangular gridworld representation of a simple finite MDP. The cells of the grid correspond to the states of the environment. At each cell, four actions are possible: **north**, **south**, **east**, and **west**, which deterministically cause the agent to move one cell in the respective direction on the grid. Actions that would take the agent off the grid leave its location unchanged, but also result in a reward of -1 . Other actions result in a reward of 0 , except those that move the agent out of the special states A and B. From state A, all four actions yield a reward of $+10$ and take the agent to A'. From state B, all actions yield a reward of $+5$ and take the agent to B'. From any other state, actions that move the agent off the grid result in a reward of -1 , and other actions result in a reward of 0 .





Figure 3.2: Gridworld example: exceptional reward dynamics (left) and state-value function for the equiprobable random policy (right).

- ¿Por qué $v_\pi(A) \neq 10$?

Políticas *óptimas*

Hay una noción de “orden” entre políticas

$$\pi \geq \pi' \iff v_{\pi}(s) \geq v_{\pi'}(s) \quad \forall s \in \mathcal{S}$$



Ciertamente debería existir algo mejor que ir random! (la que te lleva a A / B)




Ecuación de Bellman “óptima”

Definimos la política óptima como π^*

Informalmente, es el máximo sobre todas las políticas:

$$v_*(s) := \max_{\pi} v_{\pi}(s)$$



¿Qué ecuación satisface $v_*(s)$?



$$\sum_r r p(r|s, a) + \gamma \sum_{a, s'} \pi(a|s) p(s'|s, a) v_{\pi}(s') \quad \Rightarrow \quad v_*(s) = \max_a \left(\sum_{r, a} r p(r|s, a) + \gamma \sum_{s'} p(s'|s, a) v_*(s') \right)$$

Ejemplito 3.3 (S&B)

$$\mathcal{S} = \{ \text{high}, \text{low} \}$$

$$\mathcal{A}(\text{low}) = \{ \text{buscar}, \text{esperar}, \text{recargar} \} \quad \mathcal{A}(\text{high}) = \{ \text{buscar}, \text{esperar} \}$$


$$R_t = \begin{cases} +1 & \text{si agarra lata} \\ -3 & \text{se queda s/ pilas} \end{cases} \quad || r_{\text{wait}}, r_{\text{search}} \text{ son valores medios}$$



s	a	s'	$p(s' s, a)$	$r(s, a, s')$
high	search	high	α	r_{search}
high	search	low	$1 - \alpha$	r_{search}
low	search	high	$1 - \beta$	-3
low	search	low	β	r_{search}
high	wait	high	1	r_{wait}
high	wait	low	0	-
low	wait	high	0	-
low	wait	low	1	r_{wait}
low	recharge	high	1	0
low	recharge	low	0	-

Ejemplito 3.9 (S&B)

s	a	s'	$p(s' s, a)$	$r(s, a, s')$
high	search	high	α	r_{search}
high	search	low	$1 - \alpha$	r_{search}
low	search	high	$1 - \beta$	-3
low	search	low	β	r_{search}
high	wait	high	1	r_{wait}
high	wait	low	0	-
low	wait	high	0	-
low	wait	low	1	r_{wait}
low	recharge	high	1	0
low	recharge	low	0	-




Usando las env. dynamics, podemos escribir las Ecs. de Bellman “óptimas”, y eventualmente resolverlas!

$$\begin{aligned}
 v_*(\mathbf{h}) &= \max \left\{ \begin{array}{l} p(\mathbf{h}|\mathbf{h}, \mathbf{s})[r(\mathbf{h}, \mathbf{s}, \mathbf{h}) + \gamma v_*(\mathbf{h})] + p(\mathbf{l}|\mathbf{h}, \mathbf{s})[r(\mathbf{h}, \mathbf{s}, \mathbf{l}) + \gamma v_*(\mathbf{l})], \\ p(\mathbf{h}|\mathbf{h}, \mathbf{w})[r(\mathbf{h}, \mathbf{w}, \mathbf{h}) + \gamma v_*(\mathbf{h})] + p(\mathbf{l}|\mathbf{h}, \mathbf{w})[r(\mathbf{h}, \mathbf{w}, \mathbf{l}) + \gamma v_*(\mathbf{l})] \end{array} \right\} \\
 &= \max \left\{ \begin{array}{l} \alpha[r_{\mathbf{s}} + \gamma v_*(\mathbf{h})] + (1 - \alpha)[r_{\mathbf{s}} + \gamma v_*(\mathbf{l})], \\ 1[r_{\mathbf{w}} + \gamma v_*(\mathbf{h})] + 0[r_{\mathbf{w}} + \gamma v_*(\mathbf{l})] \end{array} \right\} \\
 &= \max \left\{ \begin{array}{l} r_{\mathbf{s}} + \gamma[\alpha v_*(\mathbf{h}) + (1 - \alpha)v_*(\mathbf{l})], \\ r_{\mathbf{w}} + \gamma v_*(\mathbf{h}) \end{array} \right\}.
 \end{aligned}$$

$$v_*(\mathbf{l}) = \max \left\{ \begin{array}{l} \beta r_{\mathbf{s}} - 3(1 - \beta) + \gamma[(1 - \beta)v_*(\mathbf{h}) + \beta v_*(\mathbf{l})], \\ r_{\mathbf{w}} + \gamma v_*(\mathbf{l}), \\ \gamma v_*(\mathbf{h}) \end{array} \right\}$$

Ejemplo GridWorld de nuevo


Vino el grupo 4 del futuro (semana que viene) y nos da los $v_*(s)$... ¿¿Cómo definimos la optimal policy??



Gridworld

22.0	24.4	22.0	19.4	17.5
19.8	22.0	19.8	17.8	16.0
17.8	19.8	17.8	16.0	14.4
16.0	17.8	16.0	14.4	13.0
14.4	16.0	14.4	13.0	11.7

v_*




π_*

Acá es intuitivo porque hay una noción de movimiento, y “conocemos” las dynamics (se mueve para acá, se mueve para allá...) → construimos π^*

Otro ejemplo
(y “recreo”)

Ejercicio 3.22 (S&B)



Horizonte infinito

Dos acciones (L, R)

¿Cuál es la política óptima si $\gamma = \{0, 0.9\}$?

Hint:
$$\sum_{k=0}^{\infty} x^k = \frac{1}{1-x}$$

State-action value functions

State-action value function

Hasta ahora venimos “valuando” los estados, y “dibujamos” la política óptima si tenemos v_* para algunos casos...

... pero qué pasa con el agente, si no sabe las consecuencias de las acciones? Ej. no sabe que mover a la derecha te lleva a la derecha



State-action value function [\[Shannon 1950\]](#)



Habíamos definido $v(s)$ como cuán valioso es “pararnos” en un estado, siguiendo la policy π .

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s] = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s\right]$$

State-action value function

Necesitamos ahora un objeto que nos diga cuán valioso es una acción, cuando estoy en un determinado estado



$$Q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t | S_t = s, A_t = a] = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a\right]$$

Esto es para cada par estado-acción (s,a)

Relación entre los dos objetos

- Podemos relacionar los dos objetos.
- $v(s)$ contempla seguir la policy π a partir de un estado “ s ”. Entonces:

$$v_{\pi}(s) = \mathbb{E}_{A_t \sim \pi}[Q_{\pi}(s, a)] = \sum_a \pi(a|s)Q_{\pi}(s, a)$$

Relación entre los dos objetos

- Volvamos a la recurrencia: $G_t = R_{t+1} + \gamma G_{t+1}$

$$Q_\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} | S_t = s, A_t = a\right]$$

- Si reemplazamos en cada uno de los términos, obtenemos

$$Q_\pi(s, a) = \sum_r r p(r|s, a) + \gamma \sum_{s'} p(s'|s, a) v_\pi(s')$$

¿¿ Cómo sería la Ecuación de Bellman para las Q??

Optimal Bellman Eq. for Q

$$v_*(s) := \max_{\pi} v_{\pi}(s) \quad \longrightarrow \quad Q_*(s, a) := \max_{\pi} Q_{\pi}(s, a)$$

La Eq. Bellman (pregunta anterior!) toma la forma...

$$Q_{\pi}(s, a) = \sum_r r p(r|s, a) + \gamma \sum_{s', a'} p(s'|s, a) \pi(a'|s') Q_{\pi}(s', a')$$

Y para la policy óptima...

$$Q_*(s, a) = \sum_r r p(r|s, a) + \gamma \max_{a'} \sum_{s'} p(s'|s, a) Q_{\pi}(s', a')$$

Detalles

Soluciones

Se puede probar que las funciones $v(s)$ y $q(s,a)$ son soluciones únicas de las Ecuaciones de Bellman (para una policy fija)

$$v_{\pi}(s) = \sum_{r,a} r p(r|s, a) \pi(a|s) + \gamma \sum_{a,s'} \pi(a|s) p(s'|s, a) v_{\pi}(s')$$

$$Q_{\pi}(s, a) = \sum_r r p(r|s, a) + \gamma \sum_{s',a'} p(s'|s, a) \pi(a'|s') Q_{\pi}(s', a')$$

Y esto también aplica a la policy óptima


$$v_*(s) = \max_a \left(\sum_{r,a} r p(r|s, a) + \gamma \sum_{s'} p(s'|s, a) v_*(s') \right) \quad Q_*(s, a) = \sum_r r p(r|s, a) + \gamma \max_{a'} \sum_{s'} p(s'|s, a) Q_*(s', a')$$

¿Cómo se obtienen las soluciones?

Hay muchas sub-preguntas...

pero lo que más nos interesa: **experiencia**

¿A dónde vamos?



Tarea

Leer S&B Capítul 3 (MDPs)

Para interesados, chusmear conexiones de Eq. Bellman c/

- Principio de mínima acción
- Teoría de Control continuo

(Procedimiento, lo mismo que las clases pasada!)